
CLASIFICACIÓN DE ANIMALES MEDIANTE SUS SONIDOS

Modelo de Aprendizaje Automático

**Christian Lema Vázquez
Ainhoa Loureiro Cerviño
Jaime Fernández Fernández
Rafael Alonso Ojea**

Grupo de prácticas: 3.2

**Aprendizaje Automático
Universidade da Coruña
Curso 2025/2026**

Índice

1. Introducción	1
2. Descripción del problema	3
3. Análisis bibliográfico / Estado del arte	4
4. Aplicación de modelos de AA	6
4.1. Descripción	6
4.1.1. Base de datos utilizada en esta aproximación	6
4.1.2. Extracción de características	6
4.1.3. Preprocesado y normalización	7
4.1.4. Metodología experimental	8
4.2. Resultados	8
4.2.1. Redes Neuronales Artificiales (ANN)	8
4.2.2. Máquinas de Vectores de Soporte (SVM)	10
4.2.3. k-Nearest Neighbors (kNN)	11
4.2.4. Árboles de decisión	12
4.2.5. DoME (Development of Mathematical Expressions)	13
4.2.6. Comparativa final de modelos	15
4.3. Discusión	15
5. Aplicación de Deep Learning	16
5.1. Descripción	16
5.1.1. Base de datos utilizada en esta aproximación	16
5.1.2. Representación de la señal	17
5.1.3. Normalización	17
5.1.4. División de los datos	17
5.1.5. Configuración de hiperparámetros	18
5.1.6. Arquitecturas CNN evaluadas	18
5.2. Resultados	19
5.2.1. Resultados de las arquitecturas CNN	19
5.2.2. Matriz de confusión de la mejor arquitectura	20
5.2.3. Resultados de entrenamiento	21
5.3. Discusión	22
6. Conclusiones	23
7. Trabajo futuro	23

1. Introducción

Los sonidos forman una parte fundamental de la interacción entre los seres vivos y su entorno. En la naturaleza, numerosas especies animales utilizan señales acústicas para comunicarse, advertir de peligros, atraer a otros individuos o marcar su territorio. Estos sonidos contienen información sobre el comportamiento, la identidad e incluso el estado del animal que las produce.

Desde el punto de vista científico, el análisis de estos sonidos ha dado lugar a un campo conocido como bioacústica, que estudia la producción, transmisión y recepción de señales acústicas en los animales. Mediante la observación y análisis de grabaciones de audio podemos obtener información valiosa sobre determinadas especies, sus patrones de comportamiento o los cambios que se producen en un ecosistema.

En muchos estudios de biodiversidad, los investigadores utilizan grabaciones acústicas para monitorizar la actividad de diferentes especies a lo largo del tiempo. Este análisis manual de grabaciones suele requerir la intervención de expertos capaces de reconocer los sonidos característicos de cada animal. Este proceso puede resultar lento, costoso y difícil de aplicar cuando se dispone de grandes volúmenes de datos.

En este contexto, el reconocimiento automático de sonidos animales se ha convertido en un campo de interés dentro del ámbito del aprendizaje automático. El uso de modelos computacionales permite automatizar parte de este análisis, facilitando el estudio de grandes colecciones de grabaciones y reduciendo el esfuerzo necesario para su procesamiento.

A pesar de ello, la clasificación automática de sonidos presenta varios desafíos. Entre ellos se encuentran las diferencias acústicas entre especies, la presencia de ruido ambiental, las variaciones en los dispositivos de grabación o incluso la similitud entre ciertos sonidos animales.

El objetivo de este trabajo es desarrollar un sistema capaz de clasificar sonidos de animales en diferentes categorías utilizando técnicas de Aprendizaje Automático.

De forma más concreta, los objetivos del trabajo son:

- Analizar las características de cada sonido.
- Diseñar un sistema de clasificación adecuado.
- Implementar modelos de clasificación supervisada.
- Evaluar el rendimiento del sistema mediante pruebas y métricas apropiadas.

De esta forma, el problema puede formularse como una tarea de clasificación supervisada en la que, dada una señal de audio x , el sistema debe predecir la etiqueta y correspondiente a la especie del animal que produce el sonido.

2. Descripción del problema

El problema consiste en desarrollar un sistema capaz de identificar la especie de un animal a partir de los datos obtenidos de su sonido.

Cada muestra de la base de datos corresponde a una grabación de audio, de la cual se toma un conjunto de características numéricas. Estas características forman la entrada del modelo. De esta forma, el sistema recibe como entrada un vector numérico que resume la información del sonido y debe proporcionar la especie correspondiente como salida.

Dependiendo del número de especies consideradas, el problema puede plantearse como:

- Clasificación binaria, si solo se distinguen dos especies.
- Clasificación multiclase, si se diferencian más de dos especies.

El objetivo del aprendizaje es encontrar un modelo que identifique correctamente a nuevas grabaciones no utilizadas durante el entrenamiento.

En cuanto a restricciones, el sistema se desarrolla bajo las siguientes condiciones:

- Grabaciones en formato `.wav`.
- Calidad de audio es suficientemente adecuada.
- Una especie predominante por grabación.
- Duración variable de los audios.

No vamos a considerar el funcionamiento del sistema con audios en tiempo real ni con la mezcla de múltiples especies.

Ya hablando sobre la base de datos, las grabaciones de gatos y perros proceden de un [repositorio público online](#) [1], mientras que los sonidos de vaca y rana se han obtenido de otro [repositorio público online](#) [2]. El conjunto total comprende 167 grabaciones de gatos, 113 de perros, 100 de vacas y 100 de ranas, sumando 480 muestras. Esta distribución supone un cierto desbalance entre categorías, siendo los gatos la clase mayoritaria y las vacas y ranas las minoritarias.

Todos los audios están son de 16 kHz, pero las condiciones de grabación pueden variar en diferentes aspectos:

- Nivel de ruido de fondo.
- Distancia o volumen del animal.

- Calidad del dispositivo de captura.
- Situación en la que se encuentra el animal.

Estas variaciones aumentan la complejidad del problema.

Para evaluar el rendimiento del sistema utilizaremos distintas métricas de clasificación. Las cuales son:

- **Accuracy:** mide la proporción total de clasificaciones correctas y se emplea como indicador global del rendimiento.
- **Sensibilidad:** mide la capacidad del modelo para detectar correctamente las instancias positivas, reduciendo falsos negativos.
- **Especificidad:** evalúa la capacidad del modelo para detectar correctamente las instancias negativas, reduciendo falsos positivos. (En este caso vamos a usar ambas, Sensibilidad y Especificidad para buscar un equilibrio entre ambas.)
- **Valor Predictivo Positivo:** indica la proporción de predicciones positivas que realmente son correctas.
- **F1-score:** combina VPP y la sensibilidad en una métrica. Se utiliza especialmente cuando existe posible desbalance entre clases o cuando interesa equilibrar falsos positivos y falsos negativos.

No emplearemos métricas como el error cuadrático medio, ya que el problema es de clasificación y no de regresión. Aunque se calcularán varias métricas para analizar el comportamiento del modelo, la métrica principal utilizada para comparar los resultados será el F1-score. Esto se debe a que el conjunto de datos presenta cierto desbalance entre clases, por lo que el uso exclusivo de accuracy podría ofrecer una visión incompleta del rendimiento del modelo.

3. Análisis bibliográfico / Estado del arte

La clasificación automática de sonidos animales ha sido estudiada en diferentes trabajos dentro del ámbito del aprendizaje automático. En muchos casos, el procedimiento habitual consiste en extraer primero características de audio y posteriormente aplicar un modelo de clasificación supervisada.

Algunos trabajos iniciales se centraron en el uso de clasificadores tradicionales junto con características acústicas extraídas manualmente. Por ejemplo, Acevedo et al. [3] estudiaron la clasificación automática de cantos de aves y anfibios utilizando diferentes técnicas de aprendizaje automático. En su trabajo compararon varios clasificadores, entre ellos k-

Nearest Neighbors (kNN) y Máquinas de Vectores de Soporte (SVM), observando que tanto la elección del modelo como la calidad de las características del audio influyen de forma significativa en el rendimiento.

En una línea similar, Briggs et al. [4] analizaron la clasificación automática de múltiples especies de aves presentes simultáneamente en grabaciones. Su trabajo muestra que los clasificadores basados en SVM pueden ofrecer buenos resultados incluso cuando existen niveles moderados de ruido o cuando varias especies aparecen en una misma grabación.

Otros estudios también han analizado la clasificación de sonidos ambientales desde un punto de vista más general. Cowling y Sitte [9] compararon distintas técnicas de reconocimiento de sonidos ambientales utilizando características espectrales y temporales. Sus resultados muestran que la información contenida en el espectro del sonido resulta especialmente útil para diferenciar entre distintos tipos de sonidos.

Posteriormente, con el desarrollo de técnicas más avanzadas de aprendizaje automático, comenzaron a aplicarse redes neuronales a este tipo de problemas. En particular, Piczak [5] propuso el uso de Redes Neuronales Convolucionales (CNN) aplicadas a espectrogramas para la clasificación de sonidos. En su estudio se observó que este tipo de modelos puede aprender automáticamente de representaciones del sonido, superando en algunos casos a los métodos basados en características extraídas manualmente.

De forma similar, Salamon y Bello [6] estudiaron el uso de CNN profundas para la clasificación de sonidos urbanos, mostrando que estas arquitecturas pueden mejorar el rendimiento del sistema cuando se dispone de conjuntos de datos suficientemente grandes. También, Barchiesi et al. [10] realizaron una revisión de diferentes técnicas utilizadas en clasificación de escenas acústicas, destacando la importancia de la elección de características y del modelo de aprendizaje.

En el ámbito específico de la bioacústica, algunos trabajos recientes han aplicado técnicas de aprendizaje profundo para la detección automática de especies animales. Por ejemplo, Stowell et al. [7] estudiaron la detección automática de aves utilizando redes neuronales entrenadas con grandes conjuntos de grabaciones. De la misma forma, Kahl et al. [11] desarrollaron el sistema BirdNET, basado en redes neuronales profundas, para identificar especies de aves a partir de grabaciones acústicas en entornos naturales.

Sin embargo, no todos los problemas requieren modelos extremadamente complejos. Cuando el conjunto de datos es de tamaño moderado y las características acústicas ya han sido previamente extraídas, los modelos de clasificación supervisada más sencillos pueden seguir ofreciendo buenos resultados.

4. Aplicación de modelos de AA

4.1. Descripción

4.1.1. Base de datos utilizada en esta aproximación

Para esta aproximación clásica se trabaja con el conjunto de datos descrito en la Sección 2, compuesto por 167 grabaciones de sonidos de gatos, 113 grabaciones de sonidos de perros, 100 grabaciones de sonidos de vacas y 100 grabaciones de sonidos de ranas, lo que supone un total de 480 muestras de audio en formato `.wav` a 16 kHz. La distribución entre clases presenta un desbalance (siendo los gatos la clase mayoritaria con un 34 % del total) que se tendrá en cuenta en la elección de métricas y en el diseño experimental. A diferencia de la aproximación basada en Deep Learning, en esta aproximación no se utiliza directamente la señal de audio como entrada al modelo, sino un conjunto de características numéricas extraídas de cada grabación, de modo que cada muestra queda representada como un vector de dimensión fija independientemente de la duración original del audio.

4.1.2. Extracción de características

La extracción de características acústicas es la etapa más crítica de esta aproximación, ya que la calidad de las características determina en gran medida la capacidad discriminativa del clasificador. Se han seleccionado características ampliamente utilizadas en el procesamiento de señales de audio y reconocidas en la literatura de bioacústica y clasificación de sonidos [3, 9]. Todas ellas se calculan sobre la señal de audio completa mediante análisis por tramas con longitud de ventana de 2048 muestras y desplazamiento de 512 muestras.

Los **Coefficientes Cepstrales en las Frecuencias de Mel (MFCCs)** son la característica más empleada en reconocimiento de audio y voz, ya que capturan la forma espectral de la señal de forma compacta aproximando la percepción auditiva humana mediante una escala de frecuencias mel. Se calculan los 13 primeros coeficientes aplicando un banco de 40 filtros triangulares, y de cada uno se extrae la **media** y la **desviación típica** a lo largo del tiempo, obteniendo 26 atributos en total. La media captura el valor espectral promedio del fragmento, mientras que la desviación típica refleja la variabilidad temporal, que tiende a ser distinta entre las cuatro clases consideradas. La **tasa de cruces por cero (Zero Crossing Rate, ZCR)** mide la proporción de muestras en las que la señal cambia de signo a lo largo de toda la grabación y constituye un escalar representativo de la riqueza frecuencial global del audio: las vocalizaciones de los gatos, al ser más tonales, suelen presentar una ZCR más baja que los ladridos de los perros o los sonidos de vacas y ranas, aportando 1 atributo. La **energía RMS** representa la amplitud media de la señal y permite distinguir entre sonidos

de distinta intensidad así como identificar silencios, y al igual que la ZCR se calcula como un único valor escalar sobre toda la grabación, sumando 1 atributo adicional. El **centroide espectral** indica el centro de masa del espectro de frecuencias y está relacionado con el brillo o agudeza del sonido; dado que su valor varía significativamente a lo largo del tiempo entre grabaciones, se extraen su **media** y **desviación típica**, contribuyendo con 2 atributos. El **ancho de banda espectral** mide la dispersión del espectro en torno al centroide y lo complementa para describir la distribución frecuencial de la señal, extrayéndose igualmente su **media** y **desviación típica** y aportando 2 atributos. Por último, el **rolloff espectral** es la frecuencia por debajo de la cual se concentra el 85 % de la energía espectral total, útil para distinguir sonidos de baja y alta frecuencia; se calculan su **media** y **desviación típica**, añadiendo los 2 atributos finales.

En total, el vector de características de cada muestra tiene **35 dimensiones**, tal y como se resume en la Tabla 1.

Cuadro 1: Resumen de las características extraídas de cada grabación de audio.

Característica	Estadísticos	Nº atributos
MFCCs (13 coeficientes)	Media + Desv. típica	26
Zero Crossing Rate	Escalar	1
Energía RMS	Escalar	1
Centroide espectral	Media + Desv. típica	2
Ancho de banda espectral	Media + Desv. típica	2
Rolloff espectral	Media + Desv. típica	2
Total		35

4.1.3. Preprocesado y normalización

Una vez extraídas las características, es necesario analizar sus propiedades estadísticas para decidir el tipo de normalización más adecuado. Las características acústicas como los MFCCs presentan rangos de valores muy distintos entre sí y no están acotadas a un intervalo conocido a priori: los MFCCs pueden tomar valores tanto positivos como negativos con magnitudes variables, mientras que la ZCR está acotada entre 0 y 1 y la energía RMS puede variar varios órdenes de magnitud entre grabaciones. Dado que las distribuciones de los atributos no son uniformes ni tienen rangos equivalentes, la normalización min-max entre 0 y 1 no es la opción más adecuada, ya que es muy sensible a valores atípicos presentes en los datos. Por estas razones, se opta por aplicar una **normalización z-score** (estandarización), que transforma cada atributo para que tenga media cero y desviación típica unitaria:

$$x'_i = \frac{x_i - \mu_i}{\sigma_i} \quad (1)$$

donde μ_i y σ_i son la media y la desviación típica del atributo i calculadas **exclusivamente sobre los datos de entrenamiento** de cada fold. Estos mismos parámetros se aplican posteriormente al conjunto de test, sin recalcularlos, para evitar cualquier filtración de información del conjunto de test al proceso de entrenamiento.

4.1.4. Metodología experimental

Para evaluar el rendimiento de los modelos de forma robusta y sin sesgo, se utiliza **validación cruzada estratificada con $k = 10$ folds**. La estratificación garantiza que la proporción de muestras de cada clase se mantiene aproximadamente constante en todos los folds, lo cual es especialmente relevante dado el desbalance entre clases presente en el dataset. Dado el carácter no determinístico del proceso de entrenamiento de las redes neuronales artificiales, el entrenamiento de este tipo de modelos se repite **5 veces por fold**, promediando los resultados obtenidos para obtener estimaciones más estables. Para el resto de modelos (SVM, árboles de decisión, kNN y DoME), cuyo entrenamiento es determinista, una sola ejecución por fold es suficiente. En todos los experimentos se fija una semilla aleatoria para garantizar la reproducibilidad de los resultados, reportando la **media** y la **desviación típica** de cada métrica sobre los 10 folds. Nunca se utilizan datos del conjunto de test durante el entrenamiento ni durante el cálculo de los parámetros de normalización. Las métricas empleadas son las definidas en la Sección 2: accuracy, sensibilidad, especificidad, valor predictivo positivo y F1-score, siendo esta última la métrica principal de comparación dado el desbalance entre clases.

4.2. Resultados

4.2.1. Redes Neuronales Artificiales (ANN)

Las redes neuronales artificiales constituyen uno de los modelos más utilizados en tareas de clasificación gracias a su capacidad para modelar relaciones no lineales entre las variables de entrada y las clases de salida. En este trabajo evaluamos diferentes configuraciones de arquitectura con el objetivo de determinar la topología más adecuada para la clasificación de sonidos de animales.

Se probaron un total de ocho topologías distintas, variando tanto el número de capas ocultas como el número de neuronas en cada una de ellas. Los hiperparámetros utilizados para el entrenamiento fueron los siguientes:

- Tasa de aprendizaje: 0.01

- Número máximo de épocas: 500
- Número de ejecuciones: 5
- Criterio de parada: pérdida mínima de 0.1
- Validación cruzada: 10 folds

Los resultados obtenidos para cada topología se muestran en la siguiente tabla. En esta se presentan los valores medios y la desviación típica de las métricas evaluadas sobre los 10 folds de validación cruzada.

Topología	Accuracy	Sensibilidad	Especificidad	VPP	F1-score
[32]	0.7884 $\pm$ 0.0254	0.7884 $\pm$ 0.0254	0.9211 $\pm$ 0.0081	0.8029 $\pm$ 0.0254	0.7871 $\pm$ 0.0248
[64]	0.8113 $\pm$ 0.0199	0.8113 $\pm$ 0.0199	0.9279 $\pm$ 0.0086	0.8212 $\pm$ 0.0211	0.8091 $\pm$ 0.0204
[128]	0.8152 $\pm$ 0.0307	0.8152 $\pm$ 0.0307	0.9290 $\pm$ 0.0123	0.8269 $\pm$ 0.0325	0.8129 $\pm$ 0.0325
[256]	0.8312 $\pm$ 0.0260	0.8312 $\pm$ 0.0260	0.9354 $\pm$ 0.0100	0.8417 $\pm$ 0.0282	0.8294 $\pm$ 0.0273
[64, 32]	0.7926 $\pm$ 0.0281	0.7926 $\pm$ 0.0281	0.9218 $\pm$ 0.0120	0.8044 $\pm$ 0.0256	0.7914 $\pm$ 0.0280
[128, 64]	0.8048 $\pm$ 0.0303	0.8048 $\pm$ 0.0303	0.9258 $\pm$ 0.0106	0.8188 $\pm$ 0.0336	0.8030 $\pm$ 0.0294
[256, 128]	0.8097 $\pm$ 0.0264	0.8097 $\pm$ 0.0264	0.9291 $\pm$ 0.0125	0.8239 $\pm$ 0.0286	0.8084 $\pm$ 0.0271
[128, 128]	0.8126 $\pm$ 0.0241	0.8126 $\pm$ 0.0241	0.9289 $\pm$ 0.0074	0.8269 $\pm$ 0.0249	0.8106 $\pm$ 0.0239

Matriz de confusión (mejor topología ANN)

La mejor configuración obtenida fue la topología con una única capa oculta de 256 neuronas, ya que alcanzó el mayor valor de F1-score, la métrica que usamos como criterio principal. En la matriz de confusión se muestra como el modelo tiene una alta capacidad de detección en las cuatro clases, confundiendo sobre todo entre perros y gatos y entre vacas y ranas.

	Pred: Cat	Pred: Dog	Pred: Cow	Pred: Frog
Real: Cat	146.6	9.8	2.8	4.8
Real: Dog	22.4	89.2	1.2	0.2
Real: Cow	5.0	1.8	82.6	10.6
Real: Frog	6.8	1.2	14.0	78.0

Resultados de entrenamiento

Además de las métricas obtenidas mediante validación cruzada, se calcularon también las métricas sobre el conjunto completo de entrenamiento utilizando todos los datos disponibles. Esto permite analizar el comportamiento del modelo durante el aprendizaje y detectar posibles problemas de sobreajuste.

Métrica	Training
Accuracy	0.8323
Sensibilidad	0.8323
Especificidad	0.9934
Precision	0.9934
F1-score	0.8323

Se observa que los valores obtenidos en entrenamiento son ligeramente superiores a los obtenidos en test, lo cual es algo normal y esperado en modelos de aprendizaje supervisado.

4.2.2. Máquinas de Vectores de Soporte (SVM)

Las máquinas de vectores de soporte (Support Vector Machines, SVM) son un método de aprendizaje supervisado ampliamente utilizado en problemas de clasificación, especialmente cuando los datos presentan fronteras de decisión complejas o extrañas. Este busca encontrar el hiperplano que maximiza la separación entre las distintas clases para conseguir una buena capacidad de generalización.

En este trabajo se evaluaron diferentes configuraciones del modelo SVM utilizando distintos tipos de funciones kernel y valores del parámetro de regularización C . Los hiperparámetros probados fueron los siguientes:

- Tipo de kernel: lineal y radial (RBF)
- Parámetro de regularización C : 0.1, 1, 10 y 100
- Validación cruzada: 10 folds

Resultados obtenidos

Los resultados obtenidos mediante validación cruzada para el modelo se muestran en la siguiente tabla.

Configuración	Accuracy	Sensibilidad	Especificidad	VPP	F1-score
Linear, C=0.1	0.8402 $\pm$ 0.0501	0.8402 $\pm$ 0.0501	0.9358 $\pm$ 0.0173	0.8519 $\pm$ 0.0544	0.8393 $\pm$ 0.0504
Linear, C=1.0	0.8321 $\pm$ 0.0568	0.8321 $\pm$ 0.0568	0.9340 $\pm$ 0.0217	0.8427 $\pm$ 0.0558	0.8296 $\pm$ 0.0574
Linear, C=10.0	0.8240 $\pm$ 0.0376	0.8240 $\pm$ 0.0376	0.9317 $\pm$ 0.0155	0.8274 $\pm$ 0.0376	0.8226 $\pm$ 0.0387
Linear, C=100.0	0.7793 $\pm$ 0.0667	0.7793 $\pm$ 0.0667	0.9123 $\pm$ 0.0298	0.7826 $\pm$ 0.0696	0.7773 $\pm$ 0.0693
RBF, C=0.1	0.5718 $\pm$ 0.0461	0.5718 $\pm$ 0.0461	0.8350 $\pm$ 0.0203	0.5941 $\pm$ 0.0755	0.5362 $\pm$ 0.0556
RBF, C=1.0	0.6725 $\pm$ 0.0506	0.6725 $\pm$ 0.0506	0.8798 $\pm$ 0.0190	0.6693 $\pm$ 0.0704	0.6583 $\pm$ 0.0600
RBF, C=10.0	0.7064 $\pm$ 0.0418	0.7064 $\pm$ 0.0418	0.8927 $\pm$ 0.0166	0.7106 $\pm$ 0.0462	0.7005 $\pm$ 0.0430
RBF, C=100.0	0.7587 $\pm$ 0.0343	0.7587 $\pm$ 0.0343	0.9103 $\pm$ 0.0139	0.7723 $\pm$ 0.0386	0.7578 $\pm$ 0.0328

De las distintas combinaciones, la configuración que ofrece el mejor rendimiento en términos de F1-score, es Kernel lineal y $C = 0.1$, mostrando una capacidad de generalización adecuada.

Matriz de confusión (mejor configuración SVM)

La matriz de confusión muestra que se sigue un comportamiento parecido al de las redes

neuronales, con la confusión principal entre perros y gatos, y una ligera dificultad adicional para separar vacas de ranas.

	Pred: Cat	Pred: Dog	Pred: Cow	Pred: Frog
Real: Cat	149.0	6.0	5.0	4.0
Real: Dog	23.0	88.0	1.0	1.0
Real: Cow	9.0	1.0	81.0	9.0
Real: Frog	7.0	1.0	9.0	83.0

Resultados de entrenamiento

La diferencia mínima entre los resultados de entrenamiento y validación cruzada sugiere una buena generalización sin sobreajuste significativo.

Métrica	Training
Accuracy	0.8470
F1-score	0.8470

4.2.3. k-Nearest Neighbors (kNN)

El algoritmo k-Nearest Neighbors (kNN) es un método de clasificación basado en instancias que asigna a cada muestra la clase mayoritaria de sus vecinos más cercanos en el espacio de características.

En este trabajo se evaluaron distintas configuraciones variando el número de vecinos k . Se utilizó validación cruzada estratificada de 10 folds para garantizar una evaluación robusta.

- Valores de k evaluados: 1, 3, 5, 7, 9 y 11
- Parámetro principal: número de vecinos
- Métrica de distancia: Euclídea
- Validación cruzada: 10 folds

Resultados obtenidos

La mejor configuración obtenida corresponde a un valor de $k = 3$, ya que presenta el mayor valor de F1-score.

k	Accuracy	Sensibilidad	Especificidad	VPP	F1-score
1	0.744 ± 0.0549	0.744 ± 0.0549	0.9066 ± 0.0208	0.7547 ± 0.056	0.7437 ± 0.0567
3	0.746 ± 0.0603	0.746 ± 0.0603	0.9029 ± 0.0246	0.7663 ± 0.0599	0.7453 ± 0.0609
5	0.7311 ± 0.0538	0.7311 ± 0.0538	0.9021 ± 0.0177	0.7449 ± 0.0465	0.7307 ± 0.0511
7	0.7272 ± 0.044	0.7272 ± 0.044	0.9023 ± 0.0132	0.7335 ± 0.0453	0.7253 ± 0.045
9	0.7315 ± 0.0289	0.7315 ± 0.0289	0.9025 ± 0.0114	0.743 ± 0.0212	0.7299 ± 0.0271
11	0.7397 ± 0.0442	0.7397 ± 0.0442	0.9053 ± 0.0143	0.7508 ± 0.0393	0.7393 ± 0.0426

Matriz de confusión (mejor configuración kNN)

A partir de la matriz de confusión se observa que el modelo tiene una razonable capacidad de clasificación, pero tiene un desempeño menor al de SVM y ANN, con mayor confusión en las clases de vaca y rana.

	Pred: Cat	Pred: Dog	Pred: Cow	Pred: Frog
Real: Cat	137.0	11.0	9.0	7.0
Real: Dog	22.0	84.0	7.0	0.0
Real: Cow	18.0	11.0	66.0	5.0
Real: Frog	10.0	3.0	18.0	69.0

Resultados de entrenamiento

Los valores de entrenamiento son muy similares a los de validación cruzada, lo que indica estabilidad en el modelo, pero también sugiere que el espaciado de características representado por los atributos extraídos puede que no proporcione suficiente discriminación entre las cuatro clases.

Métrica	Training
Accuracy	0.7505
F1-score	0.7505

4.2.4. Árboles de decisión

Los árboles de decisión son modelos de clasificación que dividen recursivamente el espacio de características mediante reglas simples, formando una estructura jerárquica de decisiones. Estos modelos destacan por su interpretabilidad ya que permiten visualizar el proceso de clasificación.

Evaluamos distintas configuraciones del modelo variando la profundidad máxima del árbol, con el objetivo de controlar su complejidad y evitar el sobreajuste.

- Profundidades evaluadas: 2, 4, 6, 8, 10 y 12

- Parámetro principal: profundidad máxima del árbol
- Validación cruzada: 10 folds

Resultados obtenidos

La mejor configuración obtenida corresponde a una profundidad máxima de 10 niveles.

Profundidad	Accuracy	Sensibilidad	Especificidad	VPP	F1-score
2	0.6375 ± 0.0368	0.6375 ± 0.0368	0.8889 ± 0.0150	0.7547 ± 0.0730	0.5811 ± 0.0359
4	0.7590 ± 0.0408	0.7590 ± 0.0408	0.9208 ± 0.0156	0.7950 ± 0.0419	0.7573 ± 0.0440
6	0.7929 ± 0.0493	0.7929 ± 0.0493	0.9265 ± 0.0185	0.8072 ± 0.0502	0.7924 ± 0.0541
8	0.7883 ± 0.0738	0.7883 ± 0.0738	0.9202 ± 0.0270	0.7993 ± 0.0680	0.7856 ± 0.0756
10	0.7948 ± 0.0590	0.7948 ± 0.0590	0.9246 ± 0.0204	0.8056 ± 0.0529	0.7932 ± 0.0610
12	0.7948 ± 0.0590	0.7948 ± 0.0590	0.9246 ± 0.0204	0.8056 ± 0.0529	0.7932 ± 0.0610

Matriz de confusión (mejor configuración Árbol)

En general, el árbol de decisión obtiene un rendimiento adecuado, aunque inferior a SVM, lo que sugiere que su capacidad para modelar relaciones complejas en el espacio de características es mas limitada.

	Predicho: Gato	Predicho: Perro	Predicho: Vaca	Predicho: Rana
Real: Gato	127.0	19.0	12.0	6.0
Real: Perro	17.0	89.0	4.0	3.0
Real: Vaca	9.0	2.0	82.0	7.0
Real: Rana	8.0	5.0	6.0	81.0

Resultados de entrenamiento

En este modelo se observa una diferencia moderada entre los resultados de entrenamiento y los obtenidos mediante validación cruzada, lo que sugiere que la capacidad de generalización del árbol es algo más limitada que en otros modelos evaluados.

Métrica	Training
Accuracy	0.8192
F1-score	0.8192

4.2.5. DoME (Development of Mathematical Expressions)

El modelo DoME es una técnica de regresión simbólica con el objetivo de construir expresiones matemáticas que aproximen la salida a partir de las variables de entrada. A diferencia de otros modelos, el resultado puede verse directamente como una expresión matemática en forma de árbol, compuesta por nodos terminales (variables y constantes)

y nodos no terminales (operaciones aritméticas básicas como suma, resta, multiplicación y división).

En este trabajo se evaluaron distintas configuraciones del modelo variando el número de nodos.

- Número de configuraciones evaluadas: 8
- Parámetro principal: número de nodos
- Validación cruzada: 10 folds

Resultados obtenidos

La mejor configuración obtenida corresponde a un modelo con 16 nodos.

Nodos	Accuracy	Sensibilidad	Especificidad	VPP	F1-score
2	0.3438 $\pm$ 0.0048	0.3438 $\pm$ 0.0048	0.6562 $\pm$ 0.0048	0.7744 $\pm$ 0.0015	0.1759 $\pm$ 0.0043
4	0.5071 $\pm$ 0.0400	0.5071 $\pm$ 0.0400	0.8190 $\pm$ 0.0193	0.6121 $\pm$ 0.0392	0.4432 $\pm$ 0.0401
6	0.6605 $\pm$ 0.0642	0.6605 $\pm$ 0.0642	0.8686 $\pm$ 0.0260	0.6850 $\pm$ 0.0500	0.6470 $\pm$ 0.0698
8	0.7048 $\pm$ 0.0640	0.7048 $\pm$ 0.0640	0.8846 $\pm$ 0.0267	0.7092 $\pm$ 0.0635	0.6952 $\pm$ 0.0714
10	0.7132 $\pm$ 0.0543	0.7132 $\pm$ 0.0543	0.8994 $\pm$ 0.0193	0.7232 $\pm$ 0.0566	0.7103 $\pm$ 0.0562
12	0.7275 $\pm$ 0.0397	0.7275 $\pm$ 0.0397	0.9041 $\pm$ 0.0155	0.7367 $\pm$ 0.0449	0.7220 $\pm$ 0.0429
14	0.7486 $\pm$ 0.0445	0.7486 $\pm$ 0.0445	0.9120 $\pm$ 0.0172	0.7607 $\pm$ 0.0507	0.7470 $\pm$ 0.0463
16	0.7760 $\pm$ 0.0558	0.7760 $\pm$ 0.0558	0.9196 $\pm$ 0.0200	0.7842 $\pm$ 0.0578	0.7749 $\pm$ 0.0561

Matriz de confusión (mejor configuración DoME)

En este caso vemos como hay cierta dificultad a la hora de diferenciar vacas y ranas, manteniendo los resultados con perros y gatos similares a otros modelos.

	Predicho: Gato	Predicho: Perro	Predicho: Vaca	Predicho: Rana
Real: Gato	134.0	15.0	9.0	6.0
Real: Perro	22.0	89.0	1.0	1.0
Real: Vaca	4.0	3.0	72.0	21.0
Real: Rana	9.0	4.0	12.0	75.0

Resultados de entrenamiento

Los resultados obtenidos son muy similares a los de validación, lo que indica una buena estabilidad del modelo y una capacidad de generalización adecuada, aunque con menos desempeño que otros modelos.

Métrica	Training
Accuracy	0.7694
F1-score	0.7694

4.2.6. Comparativa final de modelos

Modelo	F1-score
ANN	0.8294 ± 0.0273
SVM	0.8393 ± 0.0504
kNN	0.7453 ± 0.0609
Árbol	0.7932 ± 0.0610
DoME	0.7749 ± 0.0561

4.3. Discusión

A partir de los resultados obtenidos en la Sección 4.2, se puede realizar un análisis comparativo del comportamiento de los distintos modelos evaluados en la tarea de clasificación de sonidos animales. La métrica principal considerada ha sido el *F1-score*, debido al desbalance existente entre clases.

En primer lugar, el modelo de Máquinas de Vectores de Soporte (SVM) presenta el mejor rendimiento global, con un F1-score de 0.8393 ± 0.0504 , situándose como el modelo más equilibrado entre precisión y sensibilidad. Este resultado sugiere que las SVM son especialmente adecuadas para este problema, probablemente debido a su capacidad para encontrar fronteras de decisión óptimas en espacios de alta dimensionalidad como el generado por las características acústicas.

En segundo lugar, las Redes Neuronales Artificiales (ANN) obtienen un rendimiento muy cercano, con un F1-score de 0.8294 ± 0.0273 . Aunque ligeramente inferior al de SVM, destaca su menor desviación típica, lo que indica una mayor estabilidad entre folds. Esto sugiere que las ANN son capaces de modelar adecuadamente las relaciones no lineales del problema, aunque sin llegar a superar el rendimiento de SVM en términos de generalización.

Por otro lado, los Árboles de Decisión alcanzan un F1-score de 0.7932 ± 0.0610 , mostrando un rendimiento intermedio. Aunque son modelos fácilmente interpretables, su capacidad para capturar relaciones complejas entre características es más limitada, lo que se traduce en una menor precisión global y mayor variabilidad en los resultados.

El modelo DoME obtiene un F1-score de 0.7749 ± 0.0561 , ligeramente inferior al de los árboles de decisión. A pesar de su enfoque evolutivo y su capacidad para explorar distintas configuraciones, no logra alcanzar el rendimiento de modelos más consolidados como SVM o ANN. No obstante, presenta una estabilidad razonable y resultados consistentes, lo que indica que puede ser una alternativa válida en contextos donde se busque exploración automática de modelos.

Finalmente, el algoritmo k-Nearest Neighbors (kNN) presenta el peor rendimiento entre los modelos evaluados, con un F1-score de $0,7453 \pm 0,0609$. Este comportamiento puede explicarse por la naturaleza del modelo, que depende fuertemente de la distribución de los datos en el espacio de características. En este caso, las características extraídas no parecen proporcionar una separación suficientemente clara entre clases para que kNN funcione de manera óptima.

De forma global, los resultados muestran que los modelos más complejos y con mayor capacidad de generalización (SVM y ANN) son los que mejor se adaptan a este problema. Además, se observa que la principal dificultad de clasificación reside en la confusión entre ciertas clases, especialmente entre perros y gatos y entre vacas y ranas, lo cual es consistente en todos los modelos evaluados.

En conclusión, se puede afirmar que la selección de características acústicas empleadas resulta adecuada para la tarea, ya que permite alcanzar valores de F1-score elevados en varios modelos. Sin embargo, los resultados también indican que existe margen de mejora, especialmente en la discriminación entre clases acústicamente similares. Futuras líneas de trabajo podrían incluir el uso de técnicas más avanzadas de representación de audio o modelos basados en aprendizaje profundo que trabajen directamente sobre la señal o sobre espectrogramas.

5. Aplicación de Deep Learning

5.1. Descripción

5.1.1. Base de datos utilizada en esta aproximación

Para esta aproximación basada en Deep Learning se utiliza el mismo conjunto de datos descrito en la Sección 2, compuesto por 480 grabaciones de audio distribuidas en cuatro clases, manteniendo un ligero desbalance entre ellas:

- Gatos: 167 muestras
- Perros: 113 muestras
- Vacas: 100 muestras
- Ranas: 100 muestras

A diferencia de la aproximación clásica basada en características extraídas manualmente, en esta aproximación cada grabación se transforma en una representación frecuencial

mediante la Transformada de Fourier, que se usa directamente como entrada de una red neuronal convolucional buscando que la propia red aprenda patrones relevantes.

5.1.2. Representación de la señal

Cada grabación de audio se procesa utilizando la Transformada Rápida de Fourier (Fast Fourier Transform, FFT), con el objetivo de pasar del dominio temporal al dominio frecuencial. Esta transformación permite representar cada sonido según la intensidad de sus componentes de frecuencia, lo cual resulta útil para diferenciar sonidos animales con distintos patrones espectrales.

Tras calcular la FFT, se conserva únicamente la mitad positiva del espectro, ya que para señales reales la transformada presenta simetría y la segunda mitad no aporta información adicional relevante.

Después, todas las señales se ajustan a una longitud de 4096 valores frecuenciales. Si la representación tiene más valores se recorta, mientras que si tiene menos se completa mediante zero-padding. Esto permite que todas las entradas tengan exactamente las mismas dimensiones independientemente de la duración original del audio.

5.1.3. Normalización

Las representaciones frecuenciales obtenidas también pasan por un proceso de normalización. En este, los valores se normalizan entre 0 y 1 utilizando el valor mínimo y máximo de cada muestra.

Esta etapa facilita el entrenamiento de las redes neuronales, ya que evita que diferencias grandes de magnitud entre grabaciones afecten negativamente al proceso. Además, permite que todas las muestras sean comparables aunque existan diferencias de volumen o intensidad entre audios.

5.1.4. División de los datos

Para evaluar los modelos se utiliza validación cruzada estratificada con 10 folds. La estratificación garantiza que la proporción de muestras de cada clase se mantenga aproximadamente constante en cada partición, algo importante debido al desbalance existente entre las clases.

En cada fold, aproximadamente un 10 % de los datos se reserva como conjunto de test. El 90 % restante se vuelve a dividir para obtener un conjunto de entrenamiento y un conjunto de validación. De esta forma, la distribución aproximada en cada fold es la siguiente:

- **Entrenamiento (80 %):** Para entrenar la red convolucional
- **Validación (10 %):** Utilizado durante el entrenamiento para monitorizar el rendimiento y aplicar early stopping
- **Test (10 %):** Utilizado únicamente al final de cada fold para evaluar el rendimiento final del modelo

Esta división garantiza que no existe filtración de información del conjunto de test al proceso de entrenamiento, manteniendo la integridad de la evaluación.

5.1.5. Configuración de hiperparámetros

Los hiperparámetros utilizados en el entrenamiento de las CNN son:

- Batch size: 16
- Learning rate: 0.001
- Número máximo de épocas: 200
- Early stopping: 30 épocas sin mejora
- Inicialización aleatoria: semilla 1234

5.1.6. Arquitecturas CNN evaluadas

- **CNN_1:** arquitectura mínima con una única capa convolucional de 8 filtros, seguida de una capa de max-pooling y una capa densa de salida.
- **CNN_2:** arquitectura con dos capas convolucionales de 8 y 16 filtros, cada una seguida de max-pooling.
- **CNN_3:** arquitectura con tres capas convolucionales de 8, 16 y 32 filtros.
- **CNN_4:** variante más ancha con tres capas convolucionales de 16, 32 y 64 filtros, seguida de una capa densa intermedia de 128 neuronas, aumentando la capacidad del modelo.
- **CNN_5:** extensión de CNN_4 que incorpora capas de Dropout con probabilidades entre 0.25 y 0.40 para reducir el sobreajuste.
- **CNN_6:** arquitectura con dos capas convolucionales de 16 y 32 filtros, seguida de una capa densa intermedia de 64 neuronas.
- **CNN_7:** red ligera con dos capas convolucionales de 4 y 8 filtros.

- **CNN_8:** arquitectura similar a CNN_3, pero incorporando Batch Normalization tras cada capa convolucional, mejorando la estabilidad del entrenamiento.
- **CNN_9:** arquitectura más profunda, con cuatro capas convolucionales de 16, 32, 64 y 128 filtros, seguida de una capa densa de 256 neuronas, diseñada para capturar patrones más complejos.
- **CNN_10:** modelo muy simple con una única capa convolucional de 4 filtros, seguida de max-pooling y una capa densa de salida. Se utiliza como referencia de mínima complejidad.

5.2. Resultados

En esta sección se presentan los resultados obtenidos mediante el entrenamiento y evaluación de las distintas arquitecturas de redes neuronales convolucionales (CNN) descritas en la Sección 5.1.6. Todas las arquitecturas fueron evaluadas utilizando validación cruzada estratificada de 10 folds, manteniendo la misma configuración experimental para garantizar una comparación justa entre modelos.

Las métricas utilizadas para evaluar el rendimiento fueron accuracy, sensibilidad, especificidad, valor predictivo positivo (VPP) y F1-score, siendo esta última la métrica principal debido al ligero desbalance presente entre las clases del conjunto de datos.

5.2.1. Resultados de las arquitecturas CNN

En la Tabla 2 se muestran los resultados medios y la desviación típica obtenidos para las diez arquitecturas convolucionales evaluadas.

Arquitectura	Accuracy	Sensibilidad	Especificidad	VPP	F1-score
CNN 1	0,6387 $\pm$ 0,0632	0,6406 $\pm$ 0,0663	0,8737 $\pm$ 0,0224	0,6780 $\pm$ 0,0645	0,6462 $\pm$ 0,0656
CNN 2	0,6315 $\pm$ 0,0423	0,6259 $\pm$ 0,0405	0,8724 $\pm$ 0,0137	0,6597 $\pm$ 0,0599	0,6297 $\pm$ 0,0444
CNN 3	0,5946 $\pm$ 0,0865	0,5953 $\pm$ 0,0757	0,8604 $\pm$ 0,0259	0,6298 $\pm$ 0,0951	0,5946 $\pm$ 0,0844
CNN 4	0,5948 $\pm$ 0,0696	0,5780 $\pm$ 0,0751	0,8597 $\pm$ 0,0236	0,6668 $\pm$ 0,0757	0,5744 $\pm$ 0,0864
CNN 5	0,6528 $\pm$ 0,0925	0,6446 $\pm$ 0,1022	0,8787 $\pm$ 0,0346	0,6838 $\pm$ 0,0945	0,6451 $\pm$ 0,1050
CNN 6	0,5822 $\pm$ 0,0952	0,5683 $\pm$ 0,1220	0,8544 $\pm$ 0,0400	0,5834 $\pm$ 0,1779	0,5475 $\pm$ 0,1545
CNN 7	0,6161 $\pm$ 0,0589	0,6218 $\pm$ 0,0384	0,8678 $\pm$ 0,0168	0,6436 $\pm$ 0,0753	0,6190 $\pm$ 0,0573
CNN 8	0,6085 $\pm$ 0,0938	0,6118 $\pm$ 0,0866	0,8662 $\pm$ 0,0301	0,6317 $\pm$ 0,1026	0,6082 $\pm$ 0,0997
CNN 9	0,5839 $\pm$ 0,0971	0,5808 $\pm$ 0,1022	0,8580 $\pm$ 0,0320	0,6164 $\pm$ 0,1146	0,5742 $\pm$ 0,1056
CNN 10	0,6291 $\pm$ 0,0668	0,6288 $\pm$ 0,0595	0,8715 $\pm$ 0,0215	0,6644 $\pm$ 0,0758	0,6334 $\pm$ 0,0675

Cuadro 2: Resultados obtenidos para las arquitecturas CNN evaluadas mediante validación cruzada estratificada de 10 folds.

A partir de los resultados obtenidos se observa que las arquitecturas convolucionales consiguen un rendimiento moderado en la clasificación de sonidos animales utilizando representaciones FFT como entrada.

La mejor configuración obtenida fue la arquitectura **CNN 1**, compuesta por una única capa convolucional de 8 filtros seguida de max-pooling y una capa densa final, alcanzando un valor de F1-score de $0,6462 \pm 0,0656$.

Curiosamente, arquitecturas más profundas y complejas no consiguieron mejorar el rendimiento. Modelos como CNN 4 o CNN 9, con un número considerablemente mayor de capas y filtros, presentaron resultados inferiores. Esto sugiere que el tamaño relativamente pequeño del conjunto de datos limita la capacidad de generalización de arquitecturas más profundas, favoreciendo modelos más simples.

También se observa que la incorporación de técnicas de regularización como Dropout (CNN 5) permitió mejorar ligeramente la estabilidad del entrenamiento, alcanzando un F1-score muy cercano al mejor modelo.

5.2.2. Matriz de confusión de la mejor arquitectura

En la Tabla 3 se muestra la matriz de confusión acumulada correspondiente a la mejor arquitectura obtenida (CNN 1), calculada a partir de los resultados de los 10 folds de validación cruzada.

	Pred: Cow	Pred: Cat	Pred: Dog	Pred: Frog
Real: Cow	63	27	3	7
Real: Cat	13	104	37	10
Real: Dog	2	37	70	4
Real: Frog	10	16	6	68

Cuadro 3: Matriz de confusión acumulada (10-fold CV) para la mejor arquitectura CNN.

La matriz de confusión acumulada permite observar de forma más clara el comportamiento global del modelo sobre todas las particiones de test. Se aprecia que la red consigue clasificar correctamente la mayoría de las muestras de las cuatro clases, especialmente en los sonidos de gatos y ranas.

Sin embargo, continúan existiendo errores relevantes entre gatos y perros, siendo esta la principal fuente de confusión del modelo. En concreto, 37 muestras de perros fueron clasificadas como gatos, mientras que 37 muestras de gatos fueron clasificadas como perros.

Esto sugiere que ambas clases comparten patrones espectrales similares en determinadas grabaciones.

También se observan ciertas dificultades para diferenciar sonidos de vacas y ranas, aunque en menor medida. En particular, 27 sonidos de vacas fueron clasificados como gatos, lo que indica que algunas representaciones frecuenciales presentan características comunes que dificultan la separación entre clases.

En general, la matriz confirma que el modelo es capaz de aprender patrones relevantes a partir de la FFT, aunque todavía presenta limitaciones importantes de generalización debido al reducido tamaño del conjunto de datos.

5.2.3. Resultados de entrenamiento

Además de las métricas obtenidas mediante validación cruzada, se evaluó el rendimiento del mejor modelo utilizando el conjunto completo de entrenamiento.

Métrica	Training
Accuracy	0.8994
Sensibilidad	0.8993
Especificidad	0.9657
VPP	0.8989
F1-score	0.8990

Cuadro 4: Resultados de entrenamiento del mejor modelo CNN.

Se observa una diferencia considerable entre las métricas de entrenamiento y las obtenidas en test mediante validación cruzada. Esto indica la presencia de cierto sobreajuste (overfitting), especialmente en las arquitecturas más complejas, debido al reducido tamaño del conjunto de datos y a la alta capacidad de representación de las redes convolucionales.

Aun así, los resultados muestran que las CNN son capaces de aprender patrones frecuenciales relevantes directamente a partir de la FFT, sin necesidad de realizar una extracción manual de características como en la aproximación clásica.

5.3. Discusión

A partir de los resultados obtenidos en la sección 5.2, se observa que las arquitecturas convolucionales evaluadas no alcanzan el rendimiento obtenido previamente con los modelos clásicos. La mejor arquitectura fue CNN_1, con un F1-score de 0.6462 ± 0.0656 , mientras que en la aproximación clásica los mejores modelos superaron con creces este valor.

Un resultado destacable y a tener en cuenta es que las arquitecturas más complejas no obtuvieron mejores resultados. CNN_1, una de las configuraciones más simples, fue la que logró el mejor rendimiento, mientras que modelos más profundos como CNN_4 o CNN_9 alcanzaron valores de F1-score próximos a 0.57. Esto indica que aumentar la profundidad o el número de filtros no mejoró la capacidad de generalización del sistema.

La causa principal parece ser el tamaño limitado del conjunto de datos. Aunque se dispone de 480 grabaciones distribuidas en cuatro clases, esta cantidad sigue siendo reducida para entrenar redes convolucionales profundas. Este tipo de modelos suele necesitar un volumen de datos aún mayor para aprender patrones robustos directamente desde representaciones frecuenciales.

Además, los resultados muestran un claro problema de sobreajuste ya que el mejor modelo CNN alcanza un F1-score de 0.8990 sobre el conjunto de entrenamiento, pero desciende hasta 0.6462 ± 0.0656 en validación cruzada. Esta diferencia indica que la red aprende patrones específicos de los datos de entrenamiento, pero tiene dificultades para generalizar a muestras no vistas.

La matriz de confusión muestra que el modelo comete más errores entre clases con sonidos similares, especialmente entre gatos y perros. Esto indica que la representación basada en FFT puede resultar insuficiente para recoger ciertos patrones temporales o acústicos necesarios para distinguir correctamente estas clases.

Con todo esto, los resultados indican que para este problema en concreto la aproximación basada en Deep Learning no mejora a los modelos clásicos. Las características acústicas extraídas manualmente parecen ser más adecuadas para este conjunto de datos mientras que las CNN requerirían más datos, una representación más rica del audio o técnicas adicionales como aumento de datos para mejorar su rendimiento.

6. Conclusiones

Los resultados obtenidos muestran que el sistema es viable, sobretodo en modelos clásicos entrenados con características acústicas extraídas manualmente. Entre ellos el mejor rendimiento global se obtuvo con SVM, alcanzando un F1-score de 0.8393 ± 0.0504 . Las Redes Neuronales Artificiales también ofrecieron resultados similares, con un F1-score de 0.8294 ± 0.0273 .

En cambio la aproximación basada en Deep Learning no consiguió superar a los modelos clásicos. La mejor arquitectura convolucional fue CNN_1, con un F1-score de 0.6462 ± 0.0656 , mostrando un claro problema de sobreajuste al obtener resultados mucho mejores en entrenamiento que en validación cruzada.

Las principales dificultades encontradas fueron las diferencias entre las grabaciones, el tamaño limitado del conjunto de datos y la similitud acústica existente entre algunas clases, especialmente entre gatos y perros, y entre vacas y ranas.

En conclusión, los modelos clásicos con características acústicas manuales resultaron ser la aproximación más adecuada para este problema. Aún así el sistema podría mejorar ampliando el conjunto de datos, aplicando técnicas de aumento de datos y utilizando representaciones de audio más informativas.

7. Trabajo futuro

El sistema desarrollado clasifica sonidos de cuatro especies animales (gato, perro, vaca y rana) a partir de características acústicas extraídas manualmente. Una primera línea de trabajo sería ampliar el número de especies consideradas, lo que convertiría el problema en una tarea de clasificación multiclase de mayor complejidad, así como explorar su aplicación en otros dominios de clasificación acústica, como sonidos urbanos o ambientales. Desde el punto de vista de su aplicación práctica, el sistema podría adaptarse para procesar audio en tiempo real, lo que permitiría su uso en dispositivos de campo para la monitorización automática de fauna en entornos naturales.

En cuanto a la mejora del sistema actual, los resultados muestran que la principal dificultad reside en la confusión entre clases acústicamente similares, especialmente entre vacas y ranas. Por ello, una línea natural sería explorar conjuntos de características más ricos, así como arquitecturas de Deep Learning más avanzadas que las evaluadas, con el objetivo de mejorar la discriminación entre estas clases.

Por último, el sistema trabaja actualmente bajo la restricción de que cada grabación contiene una única especie predominante y en condiciones de audio controladas. Eliminar estas restricciones, permitiendo grabaciones con múltiples especies o con mayor nivel de ruido ambiental, acercaría el sistema a condiciones reales de uso en campo.

Referencias

- [1] mmoreaux, “Audio Cats and Dogs Dataset”, Kaggle, 2018. Disponible en: <https://www.kaggle.com/datasets/mmoreaux/audio-cats-and-dogs>
- [2] Ashutosh Sharma 091, “Animal Sound only”, Kaggle, 2026. Disponible en: <https://www.kaggle.com/datasets/ashutoshsharma091/animal-sound-only/code>
- [3] M. A. Acevedo, C. J. Corrada-Bravo, H. Corrada-Bravo, L. J. Villanueva-Rivera y T. M. Aide, “Automated classification of bird and amphibian calls using machine learning: A comparison of methods”, 2009.
- [4] F. Briggs, et al., “Acoustic classification of multiple simultaneous bird species: A multi-instance multi-label approach”, 2012.
- [5] K. J. Piczak, “Environmental sound classification with convolutional neural networks”, 2015.
- [6] J. Salamon y J. P. Bello, “Deep convolutional neural networks and data augmentation for environmental sound classification”, IEEE Signal Processing Letters, 2017.
- [7] D. Stowell, et al., “Automatic acoustic detection of birds through deep learning: The first Bird Audio Detection challenge”, Methods in Ecology and Evolution, 2019.
- [8] S. Haykin, “Neural Networks and Learning Machines”, 2009.
- [9] M. Cowling y R. Sitte, “Comparison of techniques for environmental sound recognition”, Pattern Recognition Letters, 2003.
- [10] D. Barchiesi et al., “Acoustic scene classification: Classifying environments from the sounds they produce”, IEEE Signal Processing Magazine, 2015.
- [11] S. Kahl et al., “BirdNET: A deep learning solution for avian diversity monitoring”, Ecological Informatics, 2021.